

# D1EAD – Análise Estatística para Ciência de Dados 2021.1



## Regressão Logística

*Aula baseada no curso  
Machine Learning do  
prof. Andrew Ng  
(Coursera)*

Prof. Ricardo Sovat

[sovat@ifsp.edu.br](mailto:sovat@ifsp.edu.br)

Prof. Samuel Martins (Samuka)

[samuel.martins@ifsp.edu.br](mailto:samuel.martins@ifsp.edu.br)



# Classificação Binária

**Vestibular:** Aprovado / Reprovado

**E-mail:** Spam / Não-spam

**Tumor:** Maligno / Benigno

**Assinatura:** Real / Falsa

**Tipo de app:** Gratuito / Pago

....

# Classificação Binária

**Vestibular:** Aprovado / Reprovado

**E-mail:** Spam / Não-spam

**Tumor:** Maligno / Benigno

**Assinatura:** Real / Falsa

**Tipo de app:** Gratuito / Pago

....

 **Variáveis categóricas  
com apenas 2 valores**

$$y \in \{0, 1\}$$

**0:** Classe Negativa

**1:** Classe Positiva

# Regressão Linear

$$h_{\theta}(x) = \hat{y} = \theta_0 + \theta_1 * x_1 + \dots + \theta_n * x_n$$


$$h_{\theta}(x) = \hat{y} = \theta^T * x$$

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \dots \\ \theta_n \end{bmatrix}$$


$$x = \begin{bmatrix} \overset{x_0}{\textcircled{1}} \\ x_1 \\ \dots \\ x_n \end{bmatrix}$$

$$\theta^T = [\theta_0 \ \theta_1 \ \dots \ \theta_n]$$


Em machine learning, **vetores** são  
comumente representados como  
**vetores coluna.**




# Problema de Classificação




# Problema de Classificação



# Problema de Classificação



# Problema de Classificação




Se  $h_{\theta}(x) \geq 0.5$ , classifique  $\hat{y} = 1$

Se  $h_{\theta}(x) < 0$ , classifique  $\hat{y} = 0$




# Problema de Classificação



Se  $h_{\theta}(x) \geq 0.5$ , classifique  $\hat{y} = 1$

Se  $h_{\theta}(x) < 0$ , classifique  $\hat{y} = 0$


# Problema de Classificação



Se  $h_{\theta}(x) \geq 0.5$ , classifique  $\hat{y} = 1$

Se  $h_{\theta}(x) < 0$ , classifique  $\hat{y} = 0$

# Problema de Classificação




Aplicar uma **Regressão Linear** em problemas de **classificação** não parece ser uma boa ideia

Se  $h_{\theta}(x) \geq 0.5$ , classifique  $\hat{y} = 1$

Se  $h_{\theta}(x) < 0$ , classifique  $\hat{y} = 0$

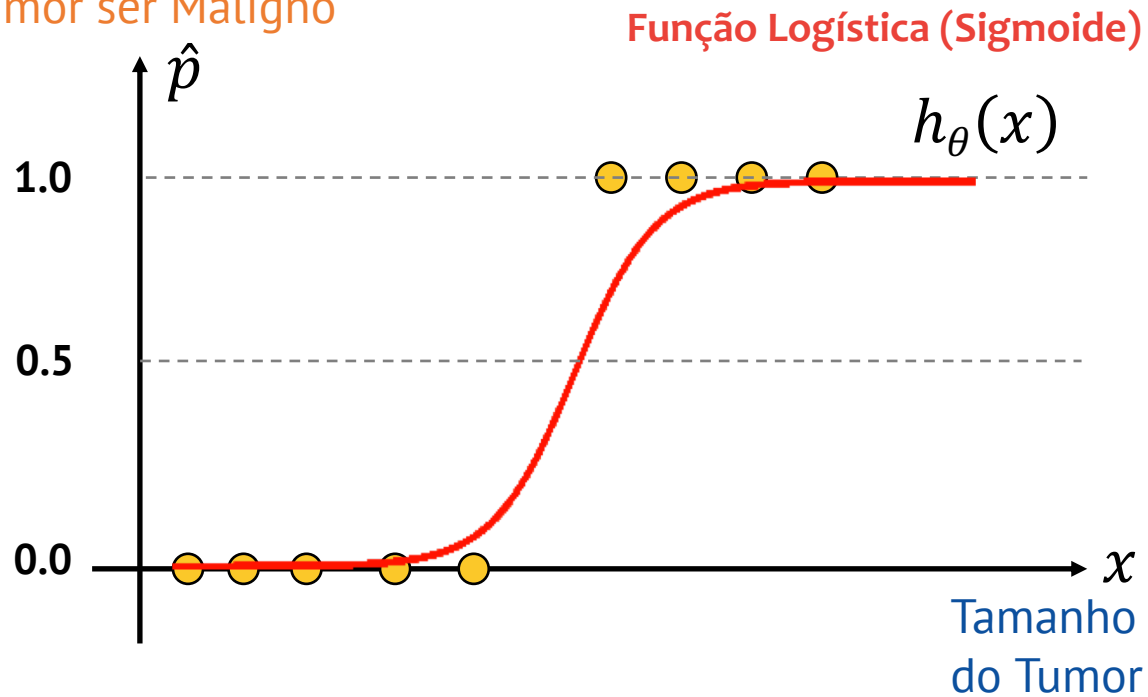
# Regressão Logística

Probabilidade  
Tumor ser Maligno



# Regressão Logística

Probabilidade  
Tumor ser Maligno



Modelo de Regressão Logística


$$\hat{p} = h_{\theta}(x) = \frac{1}{1 + e^{-(\theta^T * x)}}$$

$h_{\theta}(x)$  = Probabilidade estimada que a observação representada pelo vetor  $x$ , com os parâmetros  $\theta$ , seja da **classe positiva** ( $\hat{y} = 1$ )

$$h_{\theta}(x) = P(y = 1|x; \theta)$$

# Regressão Logística

Probabilidade  
Tumor ser Maligno



Modelo de Regressão Logística

$$\hat{p} = h_{\theta}(x) = \frac{1}{1 + e^{-(\theta^T * x)}}$$

$h_{\theta}(x)$  = Probabilidade estimada que a observação representada pelo vetor  $x$ , com os parâmetros  $\theta$ , seja da **classe positiva** ( $\hat{y} = 1$ )

$$h_{\theta}(x) = P(y = 1|x; \theta)$$


P.ex: Se

$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ tamanho\ do \\ tumor \end{bmatrix} \quad h_{\theta}(x) = \mathbf{0.7}$$

A **chance** do tumor ser **maligno** é de **70%**

# Regressão Logística

Probabilidade  
Tumor ser Maligno



Classificação

$$\hat{y} = \begin{cases} 1 & \text{se } \hat{p} \geq 0.5 \\ 0 & \text{se } \hat{p} < 0.5 \end{cases}$$

Modelo de Regressão Logística

$$\hat{p} = h_{\theta}(x) = \frac{1}{1 + e^{-(\theta^T * x)}}$$

$h_{\theta}(x)$  = Probabilidade estimada que a observação representada pelo vetor  $x$ , com os parâmetros  $\theta$ , seja da **classe positiva** ( $\hat{y} = 1$ )

$$h_{\theta}(x) = P(y = 1|x; \theta)$$

P.ex: Se

$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tamaho do tumor} \end{bmatrix} \quad h_{\theta}(x) = 0.7$$

A **chance** do tumor ser **maligno** é de **70%**

# Regressão Logística

Modelo de Regressão Logística

$$\hat{p} = h_{\theta}(x) = \sigma(f_{\theta}(x)) = \sigma(\theta^T * x) = \frac{1}{1 + e^{-(\theta^T * x)}}$$




# Regressão Logística

## Modelo de Regressão Logística

$$\hat{p} = h_{\theta}(x) = \sigma(f_{\theta}(x)) = \sigma(\theta^T * x) = \frac{1}{1 + e^{-(\theta^T * x)}}$$

## Modelo Linear

$$t = f_{\theta}(x) = \theta^T * x$$





# Regressão Logística

## Modelo de Regressão Logística

$$\hat{p} = h_{\theta}(x) = \sigma(f_{\theta}(x)) = \sigma(\theta^T * x) = \frac{1}{1 + e^{-(\theta^T * x)}}$$


## Modelo Linear

$$t = f_{\theta}(x) = \theta^T * x$$




## Função Logística (Sigmoide)

$$\hat{p} = \sigma(t) = \frac{1}{1 + e^{-t}}$$




# Regressão Logística


Modelo Linear




Função Logística (Sigmoide)



Modelo de Regressão Logística



# Função Logística (Sigmoid)



$\sigma(t)$  retorna um número entre **0** e **1**

$\sigma(t) < 0.5$  quando  $t < 0$

$\sigma(t) \geq 0.5$  quando  $t \geq 0$


O **modelo de Regressão Logística** prediz:

- **classe 1 (positiva)** se  $(\theta^T * x) \geq 0$
- **classe 0 (negativa)**: se  $(\theta^T * x) < 0$

# Treinamento e Função de Custo

Achar o vetor de parâmetros  $\theta$  de maneira que o modelo estime:


- probabilidades altas para **instâncias positivas** ( $y = 1$ );
- probabilidades baixas para **instâncias negativas** ( $y = 0$ )



## Função de Custo


$$c(\theta) = \begin{cases} -\log(h_{\theta}(x)) & \text{se } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{se } y = 0 \end{cases}$$

## Modelo de Regressão Logística




# Decision Boundary

Probabilidade  
Tumor ser Maligno



# Decision Boundary

Probabilidade  
Tumor ser Maligno



$\sigma(t)$  retorna um número entre **0** e **1**


$\sigma(t) < 0.5$  quando  $t < 0$  (**classe negativa**)

$\sigma(t) \geq 0.5$  quando  $t \geq 0$  (**classe positiva**)

$\sigma(t) = 0.5$  quando  $t = 0$

# Decision Boundary

Probabilidade  
Tumor ser Maligno



$\sigma(t)$  retorna um número entre **0** e **1**

$\sigma(t) < 0.5$  quando  $t < 0$  (**classe negativa**)


$\sigma(t) \geq 0.5$  quando  $t \geq 0$  (**classe positiva**)

$\sigma(t) = 0.5$  quando  $t = 0$



# Decision Boundary

Probabilidade  
Tumor ser Maligno



$\sigma(t)$  retorna um número entre **0** e **1**

$\sigma(t) < 0.5$  quando  $t < 0$  (**classe negativa**)

$\sigma(t) \geq 0.5$  quando  $t \geq 0$  (**classe positiva**)


$\sigma(t) = 0.5$  quando  $t = 0$



Logo, o hiperplano  $(\theta^T * x) = 0$   
forma a **decision boundary** do classificador.

# Decision Boundary

Probabilidade  
Tumor ser Maligno



$\sigma(t)$  retorna um número entre **0** e **1**

$\sigma(t) < 0.5$  quando  $t < 0$  (**classe negativa**)

$\sigma(t) \geq 0.5$  quando  $t \geq 0$  (**classe positiva**)

$\sigma(t) = 0.5$  quando  $t = 0$




Logo, o hiperplano  $(\theta^T * x) = 0$   
forma a **decision boundary** do classificador.

Suponha que o melhor vetor  $\theta$  encontrado foi:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix} = \begin{bmatrix} -4 \\ 1 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \end{bmatrix}$$

# Decision Boundary

Probabilidade  
Tumor ser Maligno



Suponha que o melhor vetor  $\theta$  encontrado foi:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix} = \begin{bmatrix} -4 \\ 1 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \end{bmatrix}$$

$\sigma(t)$  retorna um número entre **0** e **1**

$\sigma(t) < 0.5$  quando  $t < 0$  (**classe negativa**)

$\sigma(t) \geq 0.5$  quando  $t \geq 0$  (**classe positiva**)


$\sigma(t) = 0.5$  quando  $t = 0$

Logo, o hiperplano  $(\theta^T * x) = 0$   
forma a **decision boundary** do classificador.

$$\begin{aligned} \theta^T * x &= 0 \\ -4 + 1 * x_1 &= 0 \\ \boxed{x_1} &= 4 \end{aligned}$$

**decision boundary**


# Decision Boundary: outro exemplo



O hiperplano  $(\theta^T * x) = 0$   
forma a **decision boundary** do classificador.

$$h_{\theta}(x) = \sigma(\theta^T * x) = \sigma(\theta_0 + \theta_1 * x_1 + \theta_2 * x_2)$$

# Decision Boundary: outro exemplo




O hiperplano  $(\theta^T * x) = 0$   
forma a **decision boundary** do classificador.

$$h_{\theta}(x) = \sigma(\theta^T * x) = \sigma(\theta_0 + \theta_1 * x_1 + \theta_2 * x_2)$$

Suponha que o melhor vetor  $\theta$  encontrado foi:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \end{bmatrix}$$

# Decision Boundary: outro exemplo



O hiperplano  $(\theta^T * x) = 0$   
forma a **decision boundary** do classificador.

$$h_{\theta}(x) = \sigma(\theta^T * x) = \sigma(\theta_0 + \theta_1 * x_1 + \theta_2 * x_2)$$


Suponha que o melhor vetor  $\theta$  encontrado foi:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \end{bmatrix}$$

$$\begin{aligned} \theta^T * x &= 0 \\ -3 + 1 * x_1 + 1 * x_2 &= 0 \\ \boxed{x_1 + x_2} &= \boxed{3} \end{aligned}$$

**decision boundary**

# Decision Boundary: outro exemplo



$$h_{\theta}(x) = \sigma(\theta^T * x) = \sigma(\theta_0 + \theta_1 * x_1 + \theta_2 * x_2)$$

Suponha que o melhor vetor  $\theta$  encontrado foi:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix} \quad x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \end{bmatrix}$$

O hiperplano  $(\theta^T * x) = 0$   
forma a **decision boundary** do classificador.

$$\begin{aligned} \theta^T * x &= 0 \\ -3 + 1 * x_1 + 1 * x_2 &= 0 \\ \boxed{x_1 + x_2} &= 3 \end{aligned}$$

**decision boundary**

# D1EAD – Análise Estatística para Ciência de Dados 2021.1



## Regressão Logística

*Aula baseada no curso  
Machine Learning do  
prof. Andrew Ng  
(Coursera)*

Prof. Ricardo Sovat

[sovat@ifsp.edu.br](mailto:sovat@ifsp.edu.br)

Prof. Samuel Martins (Samuka)

[samuel.martins@ifsp.edu.br](mailto:samuel.martins@ifsp.edu.br)

